UNIVERSIDADE DE AVEIRO

Departamento de Eletrónica, Telecomunicações e Informática

Relatório 2

Estudo Aprofundado do Apache Superset

Cenário de Demonstração, Conformidade com Requisitos e Parecer Final

2025 / 2026

Índice

Índice....2
1. Introdução....3
2. Apresentação do Apache Superset....3
2.1 Visão Geral....3
2.2 Versão Utilizada....4
3. Cenário de Demonstração....4
3.1 Descrição do Cenário....4
3.2 Infraestrutura de Demonstração....4
3.3 Datasets de Demonstração....4
3.3.1 Domínio Académico (simulação SIGACAD)....4
3.3.2 Domínio Financeiro (simulação SIGEF)....4
3.3.3 Domínio de Recursos Humanos (simulação RHumo)....5
3.4 Dashboards Implementados....5
Dashboard 1 – Panorama Académico....5
Dashboard 2 – Execução Financeira....5
Dashboard 3 – Recursos Humanos....5
3.5 Decisões Técnicas Tomadas....5
4. Tipos de Bases de Dados das Fontes de Dados da UA....6
4.1 Estratégia de Integração....7
4.2 Conectores SQLAlchemy Necessários....7
5. Autenticação Institucional – Integração com o Sistema da UA....7
5.1 O Sistema de Autenticação da UA....7
5.2 Métodos de Autenticação Suportados pelo Apache Superset....8
5.3 Recomendação para a UA....8
5.4 Configuração OAuth2 – UA....9
5.5 Considerações de Segurança na Autenticação....10
6. Imagem Corporativa e Personalização da Interface....10
6.1 Capacidades de Personalização do Apache Superset....10
6.2 Elementos Personalizáveis....11
6.3 Configuração de Tema para a UA....11
6.4 Comparação com Outras Plataformas da UA....11
7. Estratégias de Amostragem de Dados por Conjunto de Dados....12
7.1 Princípios Orientadores da Amostragem....13
7.2 Implicações para o Apache Superset....13
8. Análise de Conformidade com os Requisitos....14
8.1 Síntese da Conformidade....15
9. Arquitetura do Sistema....16
10. Parecer de Aprovação da Ferramenta....16
10.1 Pontos Fortes Confirmados....16
10.2 Pontos de Atenção e Mitigações....16
10.3 Conclusão....17

1. Introdução

O presente relatório constitui a segunda fase do estudo para a implementação de um sistema de Business Intelligence (BI) na Universidade de Aveiro (UA), dando continuidade ao trabalho desenvolvido no Relatório 1.

Após a seleção fundamentada do Apache Superset como plataforma BI mais adequada ao contexto institucional da UA, este relatório aprofunda o estudo da ferramenta selecionada, abordando os seguintes aspetos:

- Apresentação do cenário de demonstração implementado e das decisões técnicas tomadas durante a sua implementação.
- Análise detalhada da conformidade do Apache Superset com os requisitos funcionais e não funcionais definidos no Relatório 1.
- Estudo específico das dimensões que emergiram como críticas durante a implementação: tipos de bases de dados a integrar, autenticação institucional, imagem corporativa e estratégias de amostragem de dados.
- Parecer fundamentado de aprovação ou rejeição da ferramenta para adoção em ambiente de produção na UA.

2. Apresentação do Apache Superset

2.1 Visão Geral

O Apache Superset é uma plataforma de Business Intelligence e exploração de dados de código aberto, desenvolvida originalmente pela Airbnb em 2015 e posteriormente doada à Apache Software Foundation, onde foi graduada como projeto de topo (Top-Level Project) em 2021.

A ferramenta é construída sobre uma arquitetura web moderna, com um backend em Python (Flask/SQLAlchemy) e um frontend em React/TypeScript. Esta escolha tecnológica confere-lhe elevada portabilidade, extensibilidade e compatibilidade com o ecossistema de dados moderno.

As suas principais componentes arquiteturais são:

- Backend Python (Flask + Flask-AppBuilder): responsável pela API REST, autenticação, autorização e gestão de metadados.
- SQLAlchemy: camada de abstração de bases de dados que suporta mais de 30 dialetos SQL distintos.
- Frontend React: interface web responsiva e interativa, com suporte ao sistema de temas Ant Design v5.
- Apache ECharts: biblioteca de visualização integrada, responsável pela renderização de mais de 40 tipos de gráficos.
- Celery + Redis: sistema de execução assíncrona de queries e caching, essencial para dashboards de alta performance.
- Metastore (base de dados de metadados): tipicamente PostgreSQL ou MySQL, onde o Superset armazena definições de dashboards, datasets, utilizadores e configurações.

2.2 Versão Utilizada

No cenário de demonstração foi utilizado o Apache Superset versão 6.0 (deployed via Docker Compose), que inclui as funcionalidades de SQL Lab, cross-filtering nativo, alertas por email (requer Celery) e gestão de roles RBAC. A versão 6.0, lançada em 2026, introduz melhorias significativas no sistema de temas (tokens Ant Design v5), pelo que a análise de imagem corporativa reflete as capacidades desta versão mais recente.

3. Cenário de Demonstração

3.1 Descrição do Cenário

O cenário de demonstração foi desenhado para simular um subconjunto representativo das necessidades de análise da Universidade de Aveiro, incidindo sobre três domínios temáticos principais: dados académicos, dados financeiros e dados de recursos humanos.

Dado que os sistemas reais da UA (SIGACAD, SIGEF, RHumo) não estavam disponíveis para integração direta, foram criados datasets sintéticos mas estruturalmente representativos, carregados numa instância PostgreSQL local que simula o Data Warehouse institucional.

3.2 Infraestrutura de Demonstração

A infraestrutura de demonstração foi deployed localmente através de Docker Compose, incluindo os seguintes serviços:

- Apache Superset: serviço principal de BI, acessível via browser na porta 8088.
- PostgreSQL 15: base de dados relacional que simula o Data Warehouse da UA, com os datasets de demonstração carregados em schemas separados (schema_academico, schema_financeiro, schema_rh).
- Redis 7: sistema de caching para queries e sessões.
- Celery Worker: execução assíncrona de queries longas e alertas (configuração base).

3.3 Datasets de Demonstração

Foram criados e carregados os seguintes datasets sintéticos, estruturalmente alinhados com os sistemas reais da UA:

3.3.1 Domínio Académico (simulação SIGACAD)

- alunos: identificador anonimizado, curso, departamento, ano de matrícula, estatuto (ativo/concluído/desistência).
- inscricoes_uc: aluno, unidade curricular, semestre, ano letivo, nota final, resultado (aprovado/reprovado/não avaliado).
- cursos: código, designação, departamento, ECTS totais, n.º de vagas, n.º de inscritos.

KPIs implementados: taxa de aprovação por UC e por curso; n.º de alunos inscritos por departamento; evolução de inscrições nos últimos 5 anos letivos; distribuição de notas por curso.

3.3.2 Domínio Financeiro (simulação SIGEF)

- orcamento: rubrica, departamento, dotação inicial, dotação atual, execução acumulada, percentagem de execução.
- despesas: data, rubrica, departamento, fornecedor (anonimizado), valor, estado (pago/pendente/anulado).

KPIs implementados: percentagem de execução orçamental por departamento; evolução mensal de despesas; distribuição de despesas por rubrica; comparativo dotação vs. execução.

3.3.3 Domínio de Recursos Humanos (simulação RHumo)

- colaboradores: identificador anonimizado, categoria (docente/não-docente), departamento, regime (tempo integral/parcial), data de início de contrato.
- ausencias: colaborador, tipo de ausência (férias/doença/formação/outro), data de início, data de fim, duração em dias.

KPIs implementados: headcount por departamento e categoria; taxa de absentismo mensal; distribuição por tipo de ausência; evolução do headcount nos últimos 3 anos.

3.4 Dashboards Implementados

Com base nos datasets descritos, foram criados três dashboards principais:

Dashboard 1 – Panorama Académico

Dashboard destinado à gestão académica, incluindo: scorecard com n.º total de alunos ativos, gráfico de barras com distribuição por departamento, gráfico de linhas com evolução de inscrições (2020-2025), tabela de taxa de aprovação por UC (top 10 e bottom 10) e filtros globais por departamento, curso e ano letivo. Cross-filtering ativo entre todos os widgets.

Dashboard 2 – Execução Financeira

Dashboard para gestão financeira, incluindo: scorecard com percentagem global de execução orçamental, gráfico de barras empilhadas com dotação vs. execução por departamento, gráfico de área com evolução mensal de despesas e filtros por rubrica e departamento.

Dashboard 3 – Recursos Humanos

Dashboard para gestão de RH, incluindo: scorecard com headcount total e por categoria, gráfico de pizza com distribuição por tipo de ausência, gráfico de linhas com evolução do absentismo mensal e row-level security ativa (apenas administradores de RH acedem a dados nominais; gestores acedem a dados agregados por departamento).

3.5 Decisões Técnicas Tomadas

Durante a implementação do cenário de demonstração, foram tomadas as seguintes decisões técnicas relevantes:

- Separação por schemas PostgreSQL: cada domínio temático foi isolado em schemas independentes (schema_academico, schema_financeiro, schema_rh), facilitando a gestão de permissões e a futura integração com o ETL real.
- Vistas materializadas: para as queries mais frequentes (ex: taxa de aprovação por UC), foram criadas vistas materializadas no PostgreSQL, reduzindo o tempo de resposta dos dashboards.
- Datasets virtuais no Superset: utilização de datasets baseados em SQL (virtual datasets) para cálculo de métricas derivadas (ex: taxa de aprovação = aprovados / total inscritos), evitando a necessidade de pré-calcular todas as métricas no ETL.
- Row-level security: configuração de filtros de acesso ao nível da linha para os dados de RH, garantindo que cada gestor acede apenas aos dados do seu departamento.
- Roles RBAC testadas: foram criadas e testadas as roles Admin (STIC), Analyst (analistas de dados), Manager (diretores de departamento) e Viewer (acesso somente leitura a dashboards públicos).

4. Tipos de Bases de Dados das Fontes de Dados da UA

Uma das questões centrais para a implementação do sistema de BI é compreender os tipos de bases de dados utilizados pelos diferentes sistemas da UA e como o Apache Superset se integra com cada um deles. A tabela seguinte sistematiza esta análise:

Sistema UA	Tecnologia BD Provável	Tipo de BD	Conector Superset	Observações
SIGACAD	Oracle DB / PostgreSQL	Relacional (OLTP)	cx_Oracle / psycopg2	Dados de matrículas, notas, UCs, percursos académicos.
SIGEF	Oracle DB / SQL Server	Relacional (OLTP)	cx_Oracle / pyodbc	Dados financeiros: orçamentos, despesas, receitas, contratos.
RHumo	Oracle DB / MySQL	Relacional (OLTP)	cx_Oracle / mysqlclient	Dados de RH: contratos, ausências, avaliação de desempenho, headcount.
PACO	SQL Server / PostgreSQL	Relacional (OLTP)	pyodbc / psycopg2	Interface académica dos estudantes; dados de acesso e consultas.
Sist. Gestão Projetos	PostgreSQL / MySQL	Relacional (OLTP)	psycopg2 / mysqlclient	Projetos de investigação, financiamento, milestones, equipas.
RIA	PostgreSQL (DSpace)	Relacional + metadados	psycopg2	Produção científica: artigos, teses, relatórios. Dados mais estáticos.
Data Warehouse (DW)	PostgreSQL (proposto)	Relacional (OLAP)	psycopg2	Repositório central consolidado. Alvo primário do Apache Superset.

4.1 Estratégia de Integração

A estratégia recomendada não consiste em ligar o Apache Superset diretamente aos sistemas operacionais da UA (SIGACAD, SIGEF, RHumo), mas sim através de um Data Warehouse intermediário. Esta abordagem, que foi adotada no cenário de demonstração, apresenta as seguintes vantagens:

- Isolamento dos sistemas operacionais: evita a sobrecarga de queries analíticas sobre as bases de dados de produção, minimizando o impacto no desempenho dos sistemas transacionais.
- Integração e harmonização: o processo ETL (a cargo de uma ferramenta como Apache Airflow ou KNIME) é responsável por extrair, limpar, transformar e consolidar os dados de múltiplas fontes heterogéneas no Data Warehouse.
- Modelo dimensional: o Data Warehouse é estruturado segundo um modelo dimensional (esquema em estrela), otimizado para consultas analíticas de elevada performance.
- Fonte única de verdade: o Data Warehouse constitui o repositório canónico para análise, eliminando inconsistências entre as diferentes fontes.

O Apache Superset conecta-se exclusivamente ao Data Warehouse (PostgreSQL proposto), beneficiando de todas as otimizações nele implementadas (índices, vistas materializadas, particionamento).

4.2 Conectores SQLAlchemy Necessários

Para a ligação do Apache Superset ao Data Warehouse PostgreSQL (e, se necessário, a fontes complementares), são necessários os seguintes conectores Python:

- psycopg2 ou psycopg2-binary: conector PostgreSQL (principal, para o Data Warehouse).
- cx_Oracle: conector Oracle, caso seja necessário aceder diretamente às bases de dados Oracle dos sistemas da UA durante fases de migração ou em cenários de federação de queries.
- pyodbc: conector genérico ODBC para SQL Server, caso o SIGEF ou PACO utilizem esta tecnologia.
- mysqlclient: conector MySQL, para cenários onde algum sistema auxiliar use esta base de dados.

5. Autenticação Institucional – Integração com o Sistema da UA

Uma das dimensões mais relevantes para a adoção do Apache Superset na UA é a sua capacidade de se integrar com o sistema de autenticação institucional, permitindo que os utilizadores acedam à plataforma com as mesmas credenciais que utilizam nos restantes sistemas da universidade — o denominado Utilizador Universal (UU).

5.1 O Sistema de Autenticação da UA

A Universidade de Aveiro dispõe de um sistema centralizado de identificação e autenticação — o ID-UA — que atribui a cada membro da comunidade académica um Utilizador Universal, composto por um nome de utilizador e endereço de email institucionais (@ua.pt). Este sistema, que centraliza a gestão de identidades de estudantes, docentes e funcionários não-docentes, é baseado em protocolos modernos de autorização, nomeadamente **OAuth2**, que permite a integração segura de aplicações externas.

O protocolo OAuth2 possibilita que aplicações web, como o Apache Superset, deleguem o processo de autenticação para um **Identity Provider (IdP)** institucional, responsável por validar a identidade do utilizador e emitir tokens de acesso.

5.2 Métodos de Autenticação Suportados pelo Apache Superset

O Apache Superset, construído sobre o Flask-AppBuilder (FAB), suporta nativamente os seguintes métodos de autenticação:

Método	Como Funciona	Vantagens para a UA	Requisitos Técnicos	Complexidade
LDAP / Active Directory	Superset autentica diretamente contra o servidor LDAP da UA (AUTH_TYPE = AUTH_LDAP)	Reutiliza as credenciais do Utilizador Universal (UU); sem gestão de palavras-passe locais; mapeamento automático de grupos LDAP para roles Superset.	Servidor LDAP acessível na rede; pacote python-ldap; configuração em superset_config.py	Média
OAuth2 / OIDC	Superset redireciona o utilizador para o Identity Provider (IdP) institucional que emite um token JWT.	Single sign-on verdadeiro; sessão partilhada com outros serviços da UA; suporte a MFA; sem exposição de credenciais ao Superset.	IdP institucional com suporte OIDC (ex: Keycloak, Azure AD); configuração de OAUTH_PROVIDERS	Alta
SAML 2.0	Federação de identidade entre o Superset (SP) e o IdP institucional via assertions XML assinados.	Padrão amplamente adotado em contexto universitário; compatível com SAML federations (ex: RCTSaai / eduGAIN).	python3-saml; certificados X.509; configuração de metadados SAML	Alta
Autenticação Local (Fallback)	Contas locais geridas na base de dados do Superset (AUTH_TYPE = AUTH_DB).	Útil para contas de serviço ou administração de emergência quando os sistemas de autenticação externos estão indisponíveis.	Nenhum (incluído por defeito)	Baixa

5.3 Recomendação para a UA

No contexto da Universidade de Aveiro, recomenda-se a integração do Apache Superset com o sistema de autenticação institucional através de OAuth2, visto que é o modelo utilizado pelo IDP da UA.

Esta abordagem permite implementar um mecanismo de Single Sign-On (SSO), onde o utilizador é redirecionado para o Identity Provider (IdP) da UA para autenticação, utilizando as suas credenciais institucionais.

Após a autenticação, o utilizador regressa ao Superset com um token de acesso válido, permitindo a utilização da plataforma sem necessidade de criação de contas locais.

Assim, a integração via OAuth2 representa a abordagem mais adequada e alinhada com a infraestrutura tecnológica da Universidade de Aveiro.

5.4 Configuração OAuth2 – UA

A integração do Apache Superset com o sistema de autenticação da Universidade de Aveiro deverá ser realizada através de **OAuth2**, recorrendo ao Identity Provider institucional da UA.

De acordo com a documentação oficial do Apache Superset, esta integração é configurada no ficheiro `superset_config.py`, através da definição do tipo de autenticação como `AUTH_OAUTH` e da configuração do respetivo provider.

Assim, uma configuração genérica, adaptada ao contexto da UA, poderá assumir a seguinte forma:

```
from flask_appbuilder.security.manager import AUTH_OAUTH

AUTH_TYPE = AUTH_OAUTH

OAUTH_PROVIDERS = [
    {
        "name": "ua_sso",
        "token_key": "access_token",
        "icon": "fa-address-card",
        "remote_app": {
            "client_id": "CLIENT_ID_UA",
            "client_secret": "CLIENT_SECRET_UA",
            "client_kwargs": {
                "scope": "openid profile email"
            },
            "access_token_url": "https://id.ua.pt/oauth/token",
            "authorize_url": "https://id.ua.pt/oauth/authorize",
            "api_base_url": "https://id.ua.pt/"
        }
    }
]

AUTH_USER_REGISTRATION = True
AUTH_USER_REGISTRATION_ROLE = "Gamma"
```

Nesta abordagem, o utilizador que pretenda aceder ao Superset é redirecionado para o sistema de autenticação institucional da UA. Após validação das credenciais, o Identity Provider devolve um token de acesso que permite autenticar o utilizador na plataforma sem necessidade de criação de uma palavra-passe local específica para o Superset.

Desta forma, o Apache Superset pode integrar-se com o sistema de autenticação da UA de forma segura, reutilizando as credenciais institucionais existentes e permitindo uma experiência de utilização unificada.

5.5 Considerações de Segurança na Autenticação

Tendo em conta as considerações a ter relativamente à Segurança na Autenticação, comecemos por referir que toda a comunicação com o Identity Provider (IdP) deve ser feita através de **HTTPS**, assegurando a proteção dos dados durante o processo de autenticação.

Assim, e tendo em conta que o OAuth2 utiliza **tokens de acesso**, é importante garantir:

- Validação dos tokens (expiração e autenticidade);
- Utilização de mecanismos seguros de assinatura (ex: JWT);
- Definição de tempos de sessão adequados.

Adicionalmente, devem ser consideradas as seguintes medidas:

- Proteção das credenciais da aplicação (`client_id` e `client_secret`);
- Restrição dos dados acedidos (scopes mínimos necessários);
- Atribuição correta de permissões aos utilizadores dentro do Superset.

Por fim, uma das vantagens deste modelo é o facto de o Superset **não armazenar palavras-passe**, uma vez que a autenticação é gerida pelo sistema da universidade.

6. Imagem Corporativa e Personalização da Interface

A capacidade de o Apache Superset refletir a identidade visual da UA é um requisito de usabilidade importante, garantindo que os utilizadores associam a plataforma ao ecossistema digital institucional e não a uma ferramenta genérica.

6.1 Capacidades de Personalização do Apache Superset

A partir da versão 6.0, o Apache Superset introduziu um sistema de temas robusto baseado na arquitetura de tokens do Ant Design v5, que permite a personalização completa da interface sem necessidade de recompilar o código-fonte do frontend. Esta evolução representa uma melhoria significativa face às versões anteriores, onde a personalização requer modificação direta do código JavaScript/TypeScript.

6.2 Elementos Personalizáveis

Os elementos da interface que podem ser personalizados para alinhamento com a identidade visual da UA incluem:

- Logótipo: substituição do logótipo Apache Superset pelo logótipo da UA através da configuração LOGO_TARGET_PATH e APP_ICON no superset_config.py. Suporta formatos PNG e SVG.
- Nome da aplicação: configuração APP_NAME = 'UA Analytics' para substituir o nome Superset em toda a interface.
- Cores primárias: definição das cores institucionais da UA (azul #003366 e complementares) como cores primárias do tema, aplicadas a botões, links, cabeçalhos e elementos interativos.
- Tipografia: configuração de fontes personalizadas através do token fontUrls, permitindo carregar tipografias institucionais sem reconstrução do frontend.
- Favicon: substituição do favicon pelo logótipo institucional da UA.
- Página de login: personalização do fundo, logótipo e mensagem de boas-vindas da página de autenticação.
- Temas por dashboard: possibilidade de aplicar temas visuais distintos a dashboards específicos (ex: tema azul para académico, verde para financeiro).
- Modo escuro: suporte nativo a dark mode com deteção automática das preferências do sistema operativo do utilizador.

6.3 Configuração de Tema para a UA

A configuração de tema alinhada com a identidade visual da UA seria implementada no ficheiro superset_config.py da seguinte forma:

```
# Tema UA Analytics - superset_config.py
THEME_DEFAULT = {
  "token": {
    "colorPrimary": "#003366",    # Azul institucional UA
    "colorSuccess": "#1a7340",
    "fontFamily": "Arial, Helvetica, sans-serif"
  }
}
APP_NAME = "UA Analytics"
APP_ICON = "/static/assets/images/logo_ua.png"
ENABLE_UI_THEME_ADMINISTRATION = True    # Admins gerem temas via UI
```

6.4 Comparação com Outras Plataformas da UA

A UA dispõe de um conjunto de plataformas com interface web modernizada, como o PACO, o MyUA e o portal principal ua.pt, todas apresentando um design system consistente baseado na identidade visual institucional (azul predominante, tipografia clara, layouts limpos e responsivos).

A capacidade de personalização do Apache Superset 6.0 permite alcançar um nível de coerência visual próximo destas plataformas, através da configuração do sistema de tokens de design. Embora não seja possível replicar pixel-a-pixel a identidade visual de plataformas construídas de raiz, é possível garantir uma experiência visualmente coerente e reconhecível como parte do ecossistema digital da UA.

7. Estratégias de Amostragem de Dados por Conjunto de Dados

A definição de estratégias de amostragem e atualização de dados é um aspeto crítico para garantir que os dashboards apresentam informação relevante, atualizada e sem impacto negativo nos sistemas operacionais. A estratégia deve equilibrar a frequência de atualização desejada, o volume de dados disponível e os recursos computacionais disponíveis.

A tabela seguinte sistematiza as estratégias recomendadas para cada conjunto de dados da UA:

Fonte de Dados	Dados Incluídos	Sensibilidade	Frequência de Atualização	Taxa de Amostragem / Estratégia	Métricas de Qualidade
Dados Académicos (SIGACAD)	Matrículas, notas, avaliações, inscrições em UCs	Alta (dados individuais de alunos)	Semestral (início/fim de semestre) + ad-hoc para auditorias	100% (universo completo de alunos) — sem amostragem. Queries otimizadas com índices e vistas materializadas.	Tempo de carregamento do dashboard; corretude de KPIs académicos.
Dados Financeiros (SIGEF)	Execução orçamental, despesas, receitas, contratos	Muito alta (dados financeiros sensíveis)	Mensal (fecho contabilístico) + diária para monitorização de saldos	100% (totais consolidados). Dados agregados ao nível de rubrica/departamento — sem granularidade individual exposta no BI.	Conformidade com fecho contabilístico; precisão de valores relatados.
Dados de RH (RHumo)	Headcount, contratos, ausências, avaliação de desempenho	Muito alta (dados pessoais sensíveis)	Mensal + trimestral para relatórios de desempenho	100% (universo de colaboradores). Dados anonimizados/agregados por departamento no DW para consulta geral. Dados nominais com RBAC restrito.	Conformidade RGPD; corretude de headcount e taxas de absentismo.
Dados do PACO	Acessos, consultas académicas dos estudantes	Baixa (dados de interação)	Trimestral ou por necessidade específica (análise de utilização)	Amostragem temporal pode ser aplicada (ex: 1 semana por mês) para dados de logs de acesso. Para dados académicos consultados, manter o universo completo.	Representatividade da amostra temporal; sem viés de períodos atípicos (exames).
Produção Científica (RIA)	Artigos, teses, relatórios, publicações	Baixa (dados públicos)	Anual ou semestral (dados pouco voláteis)	100% — volume de dados reduzido e estável. Carga completa a cada atualização.	Atualidade dos metadados de publicações.
Projetos de Investigação	Projetos, financiamento, equipas, milestones	Média (dados de gestão)	Mensal + por evento (aprovação/encerramento de projetos)	100% (universo de projetos ativo e histórico). Volume gerível — sem necessidade de amostragem.	Alinhamento com relatórios de financiamento externo (FCT, EU).

7.1 Princípios Orientadores da Amostragem

As estratégias de amostragem definidas na tabela anterior baseiam-se nos seguintes princípios:

- Universalidade para dados de decisão: para dados que suportam decisões estratégicas (financeiros, académicos de núcleo), não se aplica amostragem — trabalha-se com o universo completo, garantindo a integridade dos KPIs.
- Amostragem temporal para dados de interação: para dados de logs e interações (ex: acessos ao PACO), pode aplicar-se amostragem temporal (ex: selecionar uma semana representativa por mês), reduzindo o volume sem comprometer a representatividade.
- Agregação no ETL: a redução de volume não é feita por amostragem aleatória, mas por agregação intencional no processo ETL — dados individuais são consolidados em totais por departamento, período ou categoria antes de chegarem ao Data Warehouse.
- Carga incremental por defeito: após a carga inicial completa, as atualizações subsequentes devem ser incrementais (apenas registos novos ou alterados desde a última carga), minimizando o tempo de processamento e o impacto nos sistemas de origem.
- Janelas de carga off-peak: as cargas do ETL devem ser agendadas fora do horário de pico de utilização dos sistemas operacionais (ex: entre as 02h00 e as 06h00), especialmente para cargas completas ou pesadas.

7.2 Implicações para o Apache Superset

No contexto do Apache Superset, as estratégias de amostragem têm as seguintes implicações práticas:

- Caching de queries: para datasets de alta cardinalidade (ex: inscrições académicas com centenas de milhares de registos), o Superset deve ser configurado com caching agressivo (Redis) para as queries mais frequentes, evitando execuções repetidas sobre o Data Warehouse.
- Vistas materializadas: recomenda-se a pré-computação de métricas frequentemente consultadas (ex: taxa de aprovação por UC e semestre) como vistas materializadas no PostgreSQL, atualizadas pelo processo ETL, e não calculadas em tempo real pelo Superset.
- Datasets virtuais com filtros temporais: configurar datasets virtuais no Superset com filtros de período padrão (ex: último semestre, último ano letivo) para limitar o volume de dados carregados por defeito nos dashboards, com possibilidade de o utilizador expandir o intervalo se necessário.
- Alertas de qualidade de dados: configurar alertas no Superset para sinalizar automaticamente quando o volume de dados num dataset diverge significativamente do esperado (ex: 0 registos carregados após ETL), indicando possível falha no processo de carga.

8. Análise de Conformidade com os Requisitos

A tabela seguinte apresenta a análise detalhada da conformidade do Apache Superset com os requisitos funcionais e não funcionais definidos no Relatório 1, com base nos resultados obtidos durante a implementação do cenário de demonstração e na análise da documentação oficial da ferramenta.

ID	Requisito	Estado	Observações
RF01	Dashboards Interativos	**Satisfeito**	O Superset disponibiliza dashboards drag-and-drop, cross-filtering nativo e atualização automática configurável. Testado com dados do SIGACAD (carga de alunos por curso).
RF02	KPIs e Indicadores	**Satisfeito**	Suporte a Big Number, scorecards e Gauge Charts. KPIs de taxa de aprovação e execução orçamental implementados no cenário de demonstração.
RF03	Reporting	**Parcialmente Satisfeito**	Exportação CSV e Excel disponível. Relatórios periódicos por email requerem configuração adicional do Celery Beat e SMTP. Testado em ambiente de demonstração.
RF04	Análise Interativa	**Satisfeito**	SQL Lab com autocompletion, historial de queries e exportação de resultados. Drill-down por departamento/curso validado.
RF05	Visualização de Dados	**Satisfeito**	40+ tipos de visualização disponíveis. No cenário de demonstração foram utilizados gráficos de barras, linhas, treemaps e tabelas pivot.
RF06	Integração de Dados	**Satisfeito**	Conexão via SQLAlchemy a PostgreSQL (simulando SIGACAD/SIGEF). Suporte validado a CSV como fonte de dados complementar.
RF07	Gestão de Alertas	**Parcialmente Satisfeito**	Funcionalidade de alertas existe mas requer Celery + Redis ativos e configuração SMTP. Não foi possível testar em ambiente de demonstração limitado.
RNF-T01	Multi-source	**Satisfeito**	SQLAlchemy suporta PostgreSQL, Oracle, MySQL, SQL Server e SQLite. Testado com PostgreSQL e ficheiros CSV.
RNF-T02	Suporte a SQL	**Satisfeito**	SQL Lab completo com syntax highlighting, autocompletion e historial. Queries complexas (JOINs, subqueries, CTEs) executadas sem problemas.
RNF-T03	Escalabilidade	**Satisfeito (não testado a escala)**	Arquitetura suporta Celery workers e Redis cache. Em ambiente de demonstração com datasets reduzidos o desempenho foi adequado.
RNF-T04	Performance	**Satisfeito**	Dashboards carregaram em < 3s com datasets de demonstração. Caching disponível para queries frequentes.
RNF-T05	Disponibilidade	**Satisfeito (infraestrutura)**	Suportado via Docker/Kubernetes com possibilidade de configuração de alta disponibilidade. Depende da infraestrutura da UA.
RNF-I01	Sistemas Heterogéneos	**Satisfeito**	Conexão configurada ao PostgreSQL como substituto dos sistemas da UA. A integração real depende da exposição de uma base de dados intermediária (Data Warehouse).

ID	Requisito	Estado	Observações
RNF-I02	Formatos	**Satisfeito**	Suporte a SQL, CSV, Excel e Parquet validado.
RNF-I03	ETL	**Neutro**	O Superset não inclui ETL nativo. Esta responsabilidade recai sobre ferramentas externas (Apache Airflow, KNIME). O Superset consome o resultado do ETL.
RNF-S01	Autenticação	**Satisfeito (configuração necessária)**	Suporte nativo a OAuth2/OIDC, bem como a outros mecanismos de autenticação suportados pelo Flask-AppBuilder.
RNF-S02	Autorização (RBAC)	**Satisfeito**	Roles Admin, Alpha, Gamma e Viewer testadas. Row-level security configurada para dados de RH (acesso restrito por departamento).
RNF-S03	Proteção de Dados	**Satisfeito**	Dados de demonstração anonimizados. Superset suporta HTTPS e permissões por dataset.
RNF-S04	Audit Log	**Parcialmente Satisfeito**	Log de acessos disponíveis via interface de administração. Log detalhado de operações requer integração com sistema de logging externo.
RNF-U01	Interface Intuitiva	**Satisfeito**	Interface web moderna e responsiva. Utilizadores não técnicos conseguiram criar dashboards básicos em sessão de demonstração.
RNF-U02	Aprendizagem	**Parcialmente Satisfeito**	A curva de aprendizagem para administradores é elevada.
RNF-U03	Imagem Corporativa	**Satisfeito (v6.0+)**	Sistema de temas baseado em tokens Ant Design v5 permite personalização completa de cores, logótipo e tipografia sem recompilação do frontend.
RNF-U04	Acessibilidade	**Parcialmente Satisfeito**	Conformidade WCAG 2.1 parcial. Alguns elementos de visualização não são totalmente acessíveis a leitores de ecrã.

8.1 Síntese da Conformidade

Da análise apresentada, destacam-se os seguintes resultados:

- Satisfeito: 15 de 23 requisitos avaliados (65%) são integralmente satisfeitos pelo Apache Superset, sem necessidade de desenvolvimento adicional.
- Parcialmente Satisfeito: 7 de 23 requisitos (30%) são parcialmente satisfeitos, sendo que a lacuna resulta essencialmente de configuração adicional necessária (alertas, SMTP, acessibilidade) e não de limitações estruturais da ferramenta.
- Neutro: 1 requisito (ETL nativo) é classificado como neutro, uma vez que o Superset não inclui capacidades ETL — esta é uma responsabilidade de uma camada separada da arquitetura.
- Não Satisfeito: 0 requisitos classificados como não satisfeitos.

Este resultado demonstra que o Apache Superset satisfaz plenamente ou parcialmente a totalidade dos requisitos definidos, sem que nenhum seja estruturalmente inviável.

9. Arquitetura do Sistema

Abordando agora um pouco a arquitetura do sistema proposto, a mesma segue uma abordagem clássica baseada em cinco camadas principais.
Os dados são inicialmente obtidos a partir das diversas fontes da Universidade de Aveiro, sendo posteriormente processados através de um processo ETL (Extract, Transform, Load), responsável pela sua integração e transformação.
Estes dados são armazenados num Data Warehouse centralizado, que serve como fonte única de informação para análise.
O Apache Superset liga-se a este repositório para exploração e visualização dos dados, permitindo a criação de dashboards interativos com os respetivos indicadores e relatórios.

10. Parecer de Aprovação da Ferramenta

10.1 Pontos Fortes Confirmados

A implementação do cenário de demonstração e a análise aprofundada do Apache Superset permitem confirmar os seguintes pontos fortes da ferramenta, relevantes para o contexto da UA:

- **Conformidade com requisitos**: conforme apresentado na seção 8, o Superset satisfaz ou satisfaz parcialmente a totalidade dos requisitos definidos, sem rejeições estruturais.
- **Integração com PostgreSQL**: a conexão ao Data Warehouse PostgreSQL foi configurada e testada com sucesso, com excelente desempenho em queries complexas sobre os datasets de demonstração.
- **Dashboards e KPIs**: os dashboards de demonstração validam a capacidade da ferramenta para responder às necessidades de visualização e monitorização de KPIs da UA, incluindo cross-filtering, drill-down e filtros globais.
- **SQL Lab**: a funcionalidade de SQL Lab revelou-se particularmente valiosa para analistas de dados da UA, permitindo exploração ad-hoc sem limitações sobre o Data Warehouse.
- **Autenticação institucional**: o suporte a OAuth2/OIDC confirma a viabilidade da integração com o sistema de Utilizador Universal da UA, garantindo single sign-on e eliminando a proliferação de credenciais.
- **Imagem corporativa**: o sistema de temas da versão 6.0 permite uma personalização adequada da interface para alinhamento com a identidade visual institucional, sem necessidade de modificar o código-fonte.
- **Custo zero**: sendo completamente open source e gratuito, o Superset é ideal para o contexto de uma universidade pública com restrições orçamentais.
- **Comunidade ativa**: a existência de uma comunidade ativa (GitHub, Slack, eventos anuais) garante evolução contínua da ferramenta e disponibilidade de suporte comunitário.

10.2 Pontos de Atenção e Mitigações

Conseguimos também identificar um conjunto de pontos de atenção que deverão ser considerados durante a implementação em produção:

- **Complexidade de configuração**: a instalação e configuração do Superset (Docker, Celery, Redis e integração com OAuth2) exigem competências técnicas avançadas.

  Mitigação: alocar recursos técnicos disponíveis na UA para a administração da plataforma e documentar detalhadamente os procedimentos de instalação e configuração.
- **Alertas por email**: a funcionalidade de alertas requer a configuração de, por exemplo, Celery Beat e de um servidor SMTP institucional.

  Mitigação: incluir esta configuração no plano de implementação, utilizando o servidor de email da UA.
- **Acessibilidade parcial**: a conformidade WCAG 2.1 é incompleta.

  Mitigação: esta é uma limitação conhecida da ferramenta, a ser endereçada com CSS customizado para os elementos mais críticos e monitorização das melhorias introduzidas em versões futuras.
- **Integração OAuth2 e mapeamento de utilizadores**: a integração com o IdP institucional pode exigir configuração adicional do provider, mapeamento de perfis e eventual implementação de um CustomSecurityManager.

  Mitigação: validar previamente os endpoints, scopes e atributos devolvidos pelo IdP da UA.

10.3 Conclusão

Com base na análise exaustiva desenvolvida ao longo deste relatório — que compreendeu a implementação de um cenário de demonstração representativo, a análise de conformidade com os requisitos definidos no Relatório 1, o estudo das capacidades de integração com os sistemas da UA, a avaliação das possibilidades de autenticação institucional, a análise das opções de personalização da interface e a definição de estratégias de amostragem de dados — recomenda-se a aprovação do Apache Superset como plataforma de Business Intelligence da Universidade de Aveiro.

Esta recomendação fundamenta-se nos seguintes elementos decisivos:

- O Apache Superset satisfaz ou satisfaz parcialmente a totalidade dos requisitos definidos, sem nenhuma rejeição estrutural. As lacunas identificadas são de natureza configuracional e não limitações intrínsecas da ferramenta.
- A integração com o sistema de autenticação institucional (Utilizador Universal via OAuth2/OIDC) é tecnicamente viável e documentada, garantindo a continuidade do modelo de credencial única da UA.
- O custo nulo de licenciamento e a maturidade da comunidade open source tornam o Superset a opção mais sustentável a longo prazo para uma instituição pública de ensino superior.
- O cenário de demonstração validou as capacidades core da ferramenta nos três domínios temáticos prioritários da UA (académico, financeiro, recursos humanos), com resultados positivos em termos de funcionalidade, desempenho e usabilidade.
- A capacidade de personalização visual, especialmente na versão 6.0, permite uma integração coerente com o ecossistema digital da UA, sem comprometer a identidade institucional.

Com as sucessivas evoluções no desenvolvimento do trabalho, recomenda-se a realização de uma implementação faseada em ambiente institucional controlado, integrando o Apache Superset com um subconjunto real dos dados através do processo de ETL inicial e envolvendo um grupo restrito de utilizadores dos STIC e da gestão académica.

Esta abordagem permitirá validar, em contexto real, a integração com o sistema de autenticação, o comportamento da plataforma com dados reais e a sua adequação às necessidades dos utilizadores finais, antes de uma eventual extensão aos restantes domínios e perfis de utilização.