

Universidade de Aveiro

DETI



Relatório 2

Adoption of an open-source Business Intelligence System for an organization

Abel Teixeira - 113655
José Marques - 114321
Tiago Albuquerque - 112901

Índice

1. Introdução.....	3
2. Apresentação do Apache Superset.....	3
2.1 Visão Geral.....	3
2.2 Versão Utilizada.....	3
3. Cenário de Demonstração.....	4
3.1 Descrição do Cenário.....	4
3.2 Infraestrutura de Demonstração.....	4
3.3 Datasets de Demonstração.....	4
3.3.1 Domínio Académico (simulação SIGACAD).....	4
3.3.2 Domínio Financeiro (simulação SIGEF).....	4
3.3.3 Domínio de Recursos Humanos (simulação RHumo).....	5
3.3.4 Domínio de Projetos (simulação Sist. Gestão Projetos).....	5
3.3.5 Domínio de Produção Científica (simulação RIA).....	5
3.4 Dashboards Implementados.....	5
Dashboard Geral – BI_Dashboard.....	5
Dashboard Académico.....	5
3.5 Decisões Técnicas Tomadas.....	5
4. Tipos de Bases de Dados das Fontes de Dados da UA.....	6
4.1 Estratégia de Integração.....	7
4.2 Conectores SQLAlchemy Necessários.....	7
5. Autenticação Institucional – Integração com o Sistema da UA.....	7
5.1 O Sistema de Autenticação da UA.....	8
5.2 Métodos de Autenticação Suportados pelo Apache Superset.....	8
5.3 Recomendação para a UA.....	8
5.4 Configuração LDAP – Exemplo Aplicado à UA.....	9
5.5 Considerações de Segurança na Autenticação.....	9
6. Imagem Corporativa e Personalização da Interface.....	9
6.1 Capacidades de Personalização do Apache Superset.....	9
6.2 Elementos Personalizáveis.....	10
6.3 Configuração de Tema para a UA.....	10
7. Estratégias de Amostragem de Dados por Conjunto de Dados.....	10
7.1 Princípios Orientadores da Amostragem.....	11
7.2 Implicações para o Apache Superset.....	12
8. Análise de Conformidade com os Requisitos.....	12
8.1 Síntese da Conformidade.....	14
9. Parecer de Aprovação da Ferramenta.....	14
9.1 Pontos Fortes Confirmados.....	14
9.2 Pontos de Atenção e Mitigações.....	15
9.3 Parecer Final.....	15

1. Introdução

O presente relatório constitui a segunda fase do estudo para a implementação de um sistema de Business Intelligence (BI) na Universidade de Aveiro (UA), dando continuidade ao trabalho desenvolvido no Relatório 1.

Após a seleção fundamentada do Apache Superset como plataforma BI mais adequada ao contexto institucional da UA, este relatório aprofunda o estudo da ferramenta selecionada, abordando os seguintes aspetos:

- Apresentação do cenário de demonstração implementado e das decisões técnicas tomadas durante a sua implementação.
- Análise detalhada da conformidade do Apache Superset com os requisitos funcionais e não funcionais definidos no Relatório 1.
- Estudo específico das dimensões que emergiram como críticas durante a implementação: tipos de bases de dados a integrar, autenticação institucional, imagem corporativa e estratégias de amostragem de dados.
- Parecer fundamentado de aprovação ou rejeição da ferramenta para adoção em ambiente de produção na UA.

2. Apresentação do Apache Superset

2.1 Visão Geral

O Apache Superset é uma plataforma de Business Intelligence e exploração de dados de código aberto, desenvolvida originalmente pela Airbnb em 2015 e posteriormente doada à Apache Software Foundation, onde foi graduada como projeto de topo (Top-Level Project) em 2021.

A ferramenta é construída sobre uma arquitetura web moderna, com um backend em Python (Flask/SQLAlchemy) e um frontend em React/TypeScript. Esta escolha tecnológica confere-lhe elevada portabilidade, extensibilidade e compatibilidade com o ecossistema de dados moderno.

As suas principais componentes arquiteturais são:

- Backend Python (Flask + Flask-AppBuilder): responsável pela API REST, autenticação, autorização e gestão de metadados.
- SQLAlchemy: camada de abstração de bases de dados que suporta mais de 30 dialetos SQL distintos.
- Frontend React: interface web responsiva e interativa, com suporte ao sistema de temas Ant Design v5.
- Apache ECharts: biblioteca de visualização integrada, responsável pela renderização de mais de 40 tipos de gráficos.
- Celery + Redis: sistema de execução assíncrona de queries e caching, essencial para dashboards de alta performance.
- Metastore (base de dados de metadados): tipicamente PostgreSQL ou MySQL, onde o Superset armazena definições de dashboards, datasets, utilizadores e configurações.

2.2 Versão Utilizada

No cenário de demonstração foi utilizado o Apache Superset versão 6.0 (deployed via Docker Compose), que inclui as funcionalidades de SQL Lab, cross-filtering nativo, alertas por email

(requer Celery) e gestão de roles RBAC. A versão 6.0, lançada em 2026, introduz melhorias significativas no sistema de temas (tokens Ant Design v5), pelo que a análise de imagem corporativa reflete as capacidades desta versão mais recente.

3. Cenário de Demonstração

3.1 Descrição do Cenário

O cenário de demonstração foi desenhado para simular um subconjunto representativo das necessidades de análise da Universidade de Aveiro, incidindo sobre três domínios temáticos principais: dados académicos, dados financeiros e dados de recursos humanos.

Dado que este trabalho constitui uma demonstração técnica da ferramenta e não uma integração com os sistemas reais da UA, foram criados datasets sintéticos mas estruturalmente representativos dos domínios institucionais, carregados numa instância PostgreSQL local.

3.2 Infraestrutura de Demonstração

A infraestrutura de demonstração foi deployed localmente através de Docker Compose, incluindo os seguintes serviços:

- Apache Superset 6.0: serviço principal de BI, acessível via browser na porta 8088.
- PostgreSQL 15: base de dados relacional utilizada para armazenar os dados sintéticos do cenário de demonstração e também para suportar a base de metadados do Apache Superset.

Os dados foram carregados a partir de ficheiros CSV para tabelas PostgreSQL através de um pipeline ETL em dois estágios: primeiro para tabelas raw no schema staging (onde os dados são tratados como TEXT bruto), e depois transformados e validados para as tabelas finais no schema público, que são as consumidas pelo Apache Superset. Esta opção simplificou o protótipo e permitiu validar rapidamente a ligação entre a camada de dados e a camada de visualização.

3.3 Datasets de Demonstração

Foram criados e carregados os seguintes datasets sintéticos, estruturalmente alinhados com os sistemas reais da UA:

3.3.1 Domínio Académico (simulação SIGACAD)

- alunos: identificador anonimizado, curso, departamento, ano de matrícula, estatuto (ativo/concluído/desistência).
- inscricoes_uc: aluno, unidade curricular, semestre, ano letivo, nota final, resultado (aprovado/reprovado/não avaliado).
- cursos: código, designação, departamento, ECTS totais, n.º de vagas, n.º de inscritos.
- unidades_curriculares: código, designação, departamento, curso associado, ECTS, tipo (obrigatória/optativa), ano curricular.

KPIs implementados: taxa de aprovação por UC e por curso; n.º de alunos inscritos por departamento; evolução de inscrições nos últimos 5 anos letivos; distribuição de notas por curso; carga curricular (ECTS) por departamento.

3.3.2 Domínio Financeiro (simulação SIGEF)

- orçamento: rubrica, departamento, dotação inicial, dotação atual, execução acumulada, percentagem de execução.
- despesas: data, rubrica, departamento, fornecedor (anonimizado), valor, estado (pago/pendente/anulado).

KPIs implementados: percentagem de execução orçamental por departamento; evolução mensal de despesas; distribuição de despesas por rubrica; comparativo dotação vs. execução.

3.3.3 Domínio de Recursos Humanos (simulação RHumo)

- colaboradores: identificador anonimizado, categoria (docente/não-docente), departamento, regime (tempo integral/parcial), data de início de contrato.
- ausências: colaborador, tipo de ausência (férias/doença/formação/outro), data de início, data de fim, duração em dias.

KPIs implementados: headcount por departamento e categoria; taxa de absentismo mensal; distribuição por tipo de ausência; evolução do headcount nos últimos 3 anos.

3.3.4 Domínio de Projetos (simulação Sist. Gestão Projetos)

- projetos: identificador, designação, tipo (I&D/serviços/infraestrutura), departamento coordenador, financiador, orçamento total, data de início, data de fim, estado (ativo/concluído/candidatura).

KPIs implementados: n.º de projetos ativos por departamento; volume de financiamento externo captado; distribuição de projetos por tipo e financiador; evolução temporal do portfólio de projetos.

3.3.5 Domínio de Produção Científica (simulação RIA)

- publicacoes_ria: identificador, título, tipo (artigo/tese/relatório/livro), autor(es) (anonimizados), departamento, ano de publicação, revista/conferência, índice de citações (Scopus/WoS), acesso aberto (sim/não).

KPIs implementados: produção científica anual por departamento; distribuição por tipo de publicação; taxa de publicações em acesso aberto; evolução temporal da produção por área.

3.4 Dashboards Implementados

Com base nos datasets descritos, foram criados dashboards de demonstração no Apache Superset, com o objetivo de validar a capacidade da ferramenta para construir indicadores, gráficos interativos e filtros globais sobre dados institucionais simulados.

Dashboard Geral – BI_Dashboard

O dashboard geral agrega indicadores de diferentes domínios da organização, permitindo uma visão transversal sobre a instituição. Inclui indicadores como número total de alunos, execução orçamental total, taxa média de aprovação, número de colaboradores e investimento médio por departamento. Inclui ainda gráficos de comparação entre número de alunos e execução orçamental por departamento, investimento por aluno, taxa de aprovação por departamento, relação entre investimento e sucesso académico, relação entre alunos e colaboradores e relação entre ausências e taxa de aprovação.




Figure 1 : BI Dashboard

Dashboard Académico

O dashboard académico foca-se sobretudo na análise dos dados relacionados com alunos, matrículas e resultados académicos. Inclui gráficos como alunos por departamento, distribuição de alunos por estatuto, evolução das matrículas, distribuição de resultados e indicadores financeiros complementares associados ao contexto académico.




Figure 2 : Academic Dashboard

Ambos os dashboards utilizam os gráficos nativos do Apache Superset, datasets criados a partir das tabelas PostgreSQL e filtros globais, nomeadamente por departamento.

3.5 Decisões Técnicas Tomadas

Durante a implementação do cenário de demonstração, foram tomadas as seguintes decisões técnicas:

- **Utilização de Docker Compose:** a infraestrutura foi definida através de Docker Compose, permitindo arrancar de forma simples os serviços necessários ao protótipo;
- **Utilização de PostgreSQL 15:** o PostgreSQL foi escolhido como base de dados relacional para armazenar os dados sintéticos do cenário de demonstração. No protótipo, a mesma instância foi utilizada para os dados analíticos e para os metadados do Apache Superset, simplificando a configuração local;
- **Carregamento dos dados via CSV:** os dados foram organizados em ficheiros CSV e carregados automaticamente para o PostgreSQL através de scripts SQL com comandos COPY;

- **Criação de índices:** foram criados índices sobre colunas frequentemente usadas em filtros, relações e agregações, como departamento, curso, ano letivo, datas, etc;
- **Construção dos datasets e definição de algumas métricas no Superset:** os gráficos foram criados a partir de datasets ligados às tabelas da BD, com métricas gerais agregadas;
- **Utilização de filtros globais:** os dashboards foram configurados com filtros, nomeadamente por departamento, permitindo análise segmentada dos indicadores.

4. Tipos de Bases de Dados das Fontes de Dados da UA

Uma das questões centrais para uma eventual implementação do sistema de BI na UA é compreender os tipos de bases de dados utilizados pelos diferentes sistemas institucionais e como o Apache Superset se integraria com cada um deles. A análise que se segue é de natureza arquitetural e prospetiva — no protótipo desenvolvido, todos os dados são sintéticos e nenhum sistema da UA foi efetivamente ligado. A tabela seguinte sistematiza esta análise:

Sistema UA	Tecnologia BD Provável	Tipo de BD	Conector Superset	Observações
SIGACAD	Oracle DB / PostgreSQL	Relacional (OLTP)	cx_Oracle / psycopg2	Dados de matrículas, notas, UCs, percursos académicos.
SIGEF	Oracle DB / SQL Server	Relacional (OLTP)	cx_Oracle / pyodbc	Dados financeiros: orçamentos, despesas, receitas, contratos.
RHumo	Oracle DB / MySQL	Relacional (OLTP)	cx_Oracle / mysqlclient	Dados de RH: contratos, ausências, avaliação de desempenho, headcount.
PACO	SQL Server / PostgreSQL	Relacional (OLTP)	pyodbc / psycopg2	Interface académica dos estudantes; dados de acesso e consultas.
Sist. Gestão Projetos	PostgreSQL / MySQL	Relacional (OLTP)	psycopg2 / mysqlclient	Projetos de investigação, financiamento, milestones, equipas.
RIA	PostgreSQL (DSpace)	Relacional + metadados	psycopg2	Produção científica: artigos, teses, relatórios. Dados mais estáticos.
Data Warehouse (DW)	PostgreSQL (proposto)	Relacional (OLAP)	psycopg2	Repositório central consolidado. Alvo primário do Apache Superset.

4.1 Estratégia de Integração

A estratégia recomendada para uma implementação real não consiste em ligar o Apache Superset diretamente aos sistemas operacionais da UA (SIGACAD, SIGEF, RHumo), mas sim através de um Data Warehouse intermediário. No protótipo de demonstração, esta arquitetura foi simulada com dados sintéticos num PostgreSQL local. Numa implementação em produção, esta abordagem apresenta as seguintes vantagens:

- Isolamento dos sistemas operacionais: evita a sobrecarga de queries analíticas sobre as bases de dados de produção, minimizando o impacto no desempenho dos sistemas transacionais.
- Integração e harmonização: o processo ETL é responsável por extrair, limpar, transformar e consolidar os dados de múltiplas fontes heterogéneas no Data Warehouse.
- Modelo dimensional: o Data Warehouse é estruturado segundo um modelo dimensional (esquema em estrela), otimizado para consultas analíticas de elevada performance.
- Fonte única de verdade: o Data Warehouse constitui o repositório canónico para análise, eliminando inconsistências entre as diferentes fontes.

O Apache Superset conecta-se exclusivamente ao Data Warehouse (PostgreSQL proposto), beneficiando de todas as otimizações nele implementadas (índices, vistas materializadas, particionamento).

4.2 Conectores SQLAlchemy Necessários

Para a ligação do Apache Superset ao Data Warehouse PostgreSQL (e, se necessário, a fontes complementares), são necessários os seguintes conectores Python:

- psycopg2 ou psycopg2-binary: conector PostgreSQL (principal, para o Data Warehouse).
- mysqlclient: conector MySQL, para cenários onde algum sistema auxiliar use esta base de dados.

5. Autenticação Institucional – Integração com o Sistema da UA

No cenário de demonstração implementado, a autenticação foi integrada com um servidor Keycloak dedicado, utilizando o protocolo OAuth2/OIDC. Esta integração, totalmente funcional e testada, permite que os utilizadores acessem ao Apache Superset através do fluxo de Single Sign-On (SSO) do Keycloak, sem necessidade de credenciais locais no Superset. A secção que se segue descreve a implementação real realizada, bem como as opções de autenticação suportadas pelo Apache Superset para uma eventual integração com o sistema de identidade institucional da UA.

5.1 O Sistema de Autenticação da UA

A Universidade de Aveiro dispõe de um sistema centralizado de identificação e autenticação — o ID-UA — que atribui a cada membro da comunidade académica um Utilizador Universal (UU), composto por nome de utilizador e endereço de email institucionais (@ua.pt). Este sistema centraliza a gestão de identidades de estudantes, docentes e funcionários não-docentes.

Para efeitos deste protótipo, o papel do sistema de autenticação institucional da UA foi desempenhado por um servidor Keycloak (versão 26.6.2), configurado localmente com o realm ua-bi. O Keycloak é um servidor de identidade e acesso (Identity Provider – IdP) open-source amplamente adotado, que implementa os protocolos OAuth2, OpenID Connect (OIDC) e SAML 2.0. Numa implementação real, o Keycloak poderia ser o próprio IdP institucional da UA, ou a integração poderia ser feita diretamente contra o IdP existente (ex: federação RCTSaai/eduGAIN), desde que suporte OIDC.

5.2 Implementação OAuth2/OIDC com Keycloak – Realizada no Protótipo

No protótipo implementado, a autenticação OAuth2/OIDC com Keycloak foi completamente configurada e validada. A infraestrutura inclui um container Docker do Keycloak (quay.io/keycloak/keycloak:26.6.2) a correr na porta 8081, com o realm ua-bi e o client superset já configurados. O fluxo de autenticação funciona da seguinte forma:

- O utilizador acede ao Apache Superset (porta 8088) e é redirecionado para a página de login do Keycloak (porta 8081).
- O Keycloak valida as credenciais e emite um token JWT (id_token + access_token) para o Superset.
- O Superset valida o token junto ao endpoint JWKS do Keycloak (comunicação interna entre containers via rede Docker) e extrai os atributos do utilizador (username, nome, email) a partir do endpoint userinfo do OIDC.
- O id_token é guardado na sessão Flask para permitir um logout federado correto — ao terminar sessão no Superset, o utilizador é redirecionado para o endpoint de logout do Keycloak com id_token_hint, evitando a página de confirmação intermédia.
- Os roles do utilizador no Superset são sincronizados a cada login (AUTH_ROLES_SYNC_AT_LOGIN = True), com o role Admin atribuído por defeito a utilizadores autenticados via Keycloak.

A implementação requereu o desenvolvimento de um KeycloakSecurityManager personalizado (extensão do SupersetSecurityManager), que sobrepõe o método oauth_user_info para extrair corretamente os atributos do utilizador a partir do endpoint userinfo do Keycloak, e uma KeycloakLogoutView personalizada para gerir o fluxo de logout federado com id_token_hint.

Um aspeto arquitetural relevante desta configuração é a separação entre os URLs públicos e internos: o authorize_url utiliza localhost:8081 porque é o browser do utilizador que redireciona para o Keycloak, enquanto o access_token_url, api_base_url e jwks_uri utilizam o hostname interno keycloak:8080, porque são chamadas feitas pelo container do Superset diretamente ao container do Keycloak dentro da rede Docker.

5.3 Outros Métodos de Autenticação Suportados pelo Apache Superset

Para além do OAuth2/OIDC implementado, o Apache Superset suporta nativamente outros métodos de autenticação relevantes para o contexto institucional da UA, todos disponíveis através do Flask-AppBuilder:

- **LDAP / Active Directory:** autenticação direta contra o servidor LDAP da UA (AUTH_TYPE = AUTH_LDAP). Reutiliza as credenciais do Utilizador Universal sem gestão de passwords locais no Superset. Requer o pacote python-ldap e acesso de rede ao servidor LDAP institucional. É a opção de menor complexidade de implementação, mas não oferece SSO verdadeiro — o utilizador insere as credenciais diretamente no Superset.
- **SAML 2.0:** federação de identidade entre o Superset (Service Provider) e o IdP institucional via assertions XML assinados. Padrão adotado em federações universitárias como a RCTSaai/eduGAIN. Requer python3-saml e certificados X.509.
- **Autenticação Local (Fallback):** contas locais geridas na base de dados do Superset (AUTH_TYPE = AUTH_DB). Útil para contas de serviço e administração de emergência quando os sistemas externos estão indisponíveis. Incluído por defeito, sem dependências adicionais.

5.4 O que o Apache Superset Permite Configurar em Termos de Autenticação

O Apache Superset oferece um conjunto rico de capacidades de configuração no domínio da autenticação, todas expostas através do ficheiro superset_config.py e da extensão do SecurityManager:

- **Múltiplos providers OAuth2/OIDC em simultâneo:** a lista `OAAUTH_PROVIDERS` suporta vários providers configurados em paralelo (ex: Keycloak institucional e Google como alternativa), com o utilizador a escolher o método na página de login.
- **Registo automático de utilizadores:** com `AUTH_USER_REGISTRATION = True`, os utilizadores autenticados via OAuth/LDAP são automaticamente registados no Superset na primeira sessão, sem intervenção do administrador.
- **Mapeamento de roles OAuth para roles Superset:** através de `AUTH_ROLES_MAPPING` e `AUTH_ROLES_SYNC_AT_LOGIN`, os roles definidos no IdP (ex: grupos Keycloak) são mapeados automaticamente para roles RBAC do Superset (Admin, Gamma, Alpha, `sql_lab`, etc.), com sincronização a cada login.
- **Custom SecurityManager:** o Superset permite substituir completamente o gestor de segurança através de `CUSTOM_SECURITY_MANAGER`, possibilitando a personalização do fluxo de autenticação, extração de atributos de utilizador e lógica de logout — como demonstrado no protótipo com o `KeycloakSecurityManager`.
- **Row-Level Security (RLS):** para além da autenticação, o Superset suporta a definição de filtros RLS por dataset e por role, permitindo que utilizadores de diferentes departamentos vejam apenas os dados relativos à sua unidade orgânica — funcionalidade particularmente relevante para o contexto multiorganizacional da UA.
- **Backup e restauração da configuração Keycloak:** no protótipo foi implementado um script de backup do realm Keycloak (`backup_keycloak.sh`) que exporta a configuração completa do realm `ua-bi` (clientes, utilizadores, roles, mapeamentos) para um ficheiro JSON, permitindo restaurar o ambiente de autenticação de forma automatizada.

6. Imagem Corporativa e Personalização da Interface

A capacidade de o Apache Superset refletir a identidade visual da UA é um requisito de usabilidade importante, garantindo que os utilizadores associam a plataforma ao ecossistema digital institucional e não a uma ferramenta genérica.

6.1 Capacidades de Personalização do Apache Superset

A partir da versão 6.0, o Apache Superset introduziu um sistema de temas robusto baseado na arquitetura de tokens do Ant Design v5, que permite a personalização completa da interface sem necessidade de recompilar o código-fonte do frontend. Esta evolução representa uma melhoria significativa face às versões anteriores, onde a personalização requer modificação direta do código JavaScript/TypeScript.

6.2 Elementos Personalizáveis

Os elementos da interface que podem ser personalizados para alinhamento com a identidade visual da UA incluem:

- **Logótipo:** substituição do logótipo Apache Superset pelo logótipo da UA através da configuração `LOGO_TARGET_PATH` e `APP_ICON` no `superset_config.py`. Suporta formatos PNG e SVG.
- **Nome da aplicação:** configuração `APP_NAME = 'UA BI'` para substituir o nome Superset em toda a interface.
- **Cores primárias:** definição das cores institucionais da UA (verde `#84BD00` como cor primária e preto `#000000` na barra de navegação) como cores do tema, aplicadas a botões, links, cabeçalhos e elementos interativos.
- **Tipografia:** configuração de fontes personalizadas através do token `fontUrls`, permitindo carregar tipografias institucionais sem reconstrução do frontend.

- Favicon: substituição do favicon pelo logótipo institucional da UA.
- Página de login: personalização do fundo, logótipo e mensagem de boas-vindas da página de autenticação.
- Temas por dashboard: possibilidade de aplicar temas visuais distintos a dashboards específicos (ex: tema azul para académico, verde para financeiro).
- Modo escuro: suporte nativo a dark mode com deteção automática das preferências do sistema operativo do utilizador.




Figure 3 : UA theme

6.3 Configuração de Tema para a UA

A configuração de tema alinhada com a identidade visual da UA seria implementada no ficheiro `superset_config.py` da seguinte forma:

```
# Excerto relevante do superset_config.py
UA_LOGO = "/ua-logo.png"
APP_NAME = "UA BI"
APP_ICON = UA_LOGO
APP_ICON_WIDTH = 160
LOGO_TARGET_PATH = "/superset/welcome/"
THEME_DEFAULT = {
    "token": {
        "colorPrimary": "#84BD00"    # Verde institucional UA
    }
}
```

7. Estratégias de Amostragem de Dados por Conjunto de Dados

A definição de estratégias de amostragem e atualização de dados é um aspeto crítico para garantir que os dashboards apresentam informação relevante, atualizada e sem impacto negativo nos sistemas operacionais. A análise seguinte é de carácter prospetivo — no protótipo desenvolvido, os dados são sintéticos e estáticos, pelo que não existe ETL incremental nem impacto em sistemas reais. As estratégias aqui definidas destinam-se a orientar uma eventual implementação em produção na UA, devendo equilibrar a frequência de atualização desejada, o volume de dados disponível e os recursos computacionais disponíveis.

A tabela seguinte sistematiza as estratégias recomendadas para cada conjunto de dados da UA:

Fonte de Dados	Dados Incluídos	Sensibilidade	Frequência de Atualização	Taxa de Amostragem / Estratégia	Métricas de Qualidade
Dados Académicos (SIGACAD)	Matrículas, notas, avaliações,	Alta (dados)	Semestral (início/fim de semestre) +	100% (universo completo de alunos) — sem amostragem.	Tempo de carregamento do dashboard;

Fonte de Dados	Dados Incluídos	Sensibilidade	Frequência de Atualização	Taxa de Amostragem / Estratégia	Métricas de Qualidade
	inscrições em UCs	individuais de alunos)	ad-hoc para auditorias	Queries otimizadas com índices e vistas materializadas.	corretude de KPIs académicos.
Dados Financeiros (SIGEF)	Execução orçamental, despesas, receitas, contratos	Muito alta (dados financeiros sensíveis)	Mensal (fecho contabilístico) + diária para monitorização de saldos	100% (totais consolidados). Dados agregados ao nível de rubrica/departamento — sem granularidade individual exposta no BI.	Conformidade com fecho contabilístico; precisão de valores relatados.
Dados de RH (RHumo)	Headcount, contratos, ausências, avaliação de desempenho	Muito alta (dados pessoais sensíveis)	Mensal + trimestral para relatórios de desempenho	100% (universo de colaboradores). Dados anonimizados/agregados por departamento no DW para consulta geral. Dados nominais com RBAC restrito.	Conformidade RGPD; corretude de headcount e taxas de absentismo.
Dados do PACO	Acessos, consultas académicas dos estudantes	Baixa (dados de interação)	Trimestral ou por necessidade específica (análise de utilização)	Amostragem temporal pode ser aplicada (ex: 1 semana por mês) para dados de logs de acesso. Para dados académicos consultados, manter o universo completo.	Representatividade da amostra temporal; sem viés de períodos atípicos (exames).
Produção Científica (RIA)	Artigos, teses, relatórios, publicações	Baixa (dados públicos)	Anual ou semestral (dados pouco voláteis)	100% — volume de dados reduzido e estável. Carga completa a cada atualização.	Atualidade dos metadados de publicações.
Projetos de Investigação	Projetos, financiamento, equipas, milestones	Média (dados de gestão)	Mensal + por evento (aprovação/enceramento de projetos)	100% (universo de projetos ativo e histórico). Volume gerível — sem necessidade de amostragem.	Alinhamento com relatórios de financiamento externo (FCT, EU).

7.1 Princípios Orientadores da Amostragem

As estratégias de amostragem definidas na tabela anterior baseiam-se nos seguintes princípios:

- **Universalidade para dados de decisão:** para dados que suportam decisões estratégicas (financeiros, académicos de núcleo), não se aplica a amostragem — trabalha-se com o universo completo, garantindo a integridade dos KPIs.
- **Amostragem temporal para dados de interação:** para dados de logs e interações (ex: acessos ao PACO), pode aplicar-se amostragem temporal (ex: selecionar uma semana representativa por mês), reduzindo o volume sem comprometer a representatividade.
- **Agregação no ETL:** a redução de volume não é feita por amostragem aleatória, mas por agregação intencional no processo ETL — dados individuais são consolidados em totais por departamento, período ou categoria antes de chegarem ao Data Warehouse.

- Carga incremental por defeito: após a carga inicial completa, as atualizações subsequentes devem ser incrementais (apenas registos novos ou alterados desde a última carga), minimizando o tempo de processamento e o impacto nos sistemas de origem.
- Janelas de carga off-peak: as cargas do ETL devem ser agendadas fora do horário de pico de utilização dos sistemas operacionais (ex: entre as 02h00 e as 06h00), especialmente para cargas completas ou pesadas.

7.2 Implicações para o Apache Superset

No contexto do Apache Superset, as estratégias de amostragem têm as seguintes implicações práticas:

- Caching de queries: para datasets de alta cardinalidade (ex: inscrições académicas com centenas de milhares de registos), o Superset deve ser configurado com caching agressivo (Redis) para as queries mais frequentes, evitando execuções repetidas sobre o Data Warehouse.
- Vistas materializadas: recomenda-se a pré-computação de métricas frequentemente consultadas (ex: taxa de aprovação por UC e semestre) como vistas materializadas no PostgreSQL, atualizadas pelo processo ETL, e não calculadas em tempo real pelo Superset.
- Datasets virtuais com filtros temporais: configurar datasets virtuais no Superset com filtros de período padrão (ex: último semestre, último ano letivo) para limitar o volume de dados carregados por defeito nos dashboards, com possibilidade de o utilizador expandir o intervalo se necessário.
- Alertas de qualidade de dados: configurar alertas no Superset para sinalizar automaticamente quando o volume de dados num dataset diverge significativamente do esperado (ex: 0 registos carregados após ETL), indicando possível falha no processo de carga.

8. Análise de Conformidade com os Requisitos

A tabela seguinte apresenta a análise detalhada da conformidade do Apache Superset com os requisitos funcionais e não funcionais definidos no Relatório 1, com base nos resultados obtidos durante a implementação do cenário de demonstração e na análise da documentação oficial da ferramenta.

ID	Requisito	Estado	Observações
RF01	Dashboards Interativos	Satisfeito	O Superset disponibiliza dashboards drag-and-drop, cross-filtering nativo e atualização automática configurável. Testado com dados sintéticos do domínio académico (carga de alunos por curso).
RF02	KPIs e Indicadores	Satisfeito	Suporte a Big Number, scorecards e Gauge Charts. KPIs de taxa de aprovação e execução orçamental implementados no cenário de demonstração.
RF03	Reporting	Parcialmente Satisfeito	Exportação CSV e Excel disponível.
RF04	Análise Interativa	Satisfeito	SQL Lab com autocompletion, historial de queries e exportação de resultados. Drill-down por departamento/curso validado.
RF05	Visualização de Dados	Satisfeito	mais de 34 tipos de visualizações disponíveis. No cenário de demonstração foram utilizados gráficos de barras, linhas, pie chart e tabelas pivot.

ID	Requisito	Estado	Observações
RF06	Integração de Dados	Satisfeito	Conexão via SQLAlchemy a PostgreSQL com dados sintéticos dos domínios académico e financeiro. Suporte validado a CSV como fonte de dados complementar.
RF07	Gestão de Alertas	Parcialmente Satisfeito	A funcionalidade é suportada pela plataforma, mas não foi configurada no ambiente de demonstração.
RNF-T01	Multi-source	Satisfeito	SQLAlchemy suporta PostgreSQL, Oracle, MySQL, SQL Server e SQLite. Testado com PostgreSQL e ficheiros CSV.
RNF-T02	Suporte a SQL	Satisfeito	SQL Lab completo com syntax highlighting, autocompletion e historial. Queries complexas (JOINS, subqueries, CTEs) executadas sem problemas.
RNF-T03	Escalabilidade	Parcialmente Satisfeito	A arquitetura do Superset permite escalar com workers, cache e deployment mais robustos, mas o protótipo foi executado localmente com apenas Superset e PostgreSQL.
RNF-T04	Performance	Satisfeito	O desempenho foi adequado com os datasets sintéticos utilizados. Não foram realizados testes de carga com volumes reais da UA.
RNF-T05	Disponibilidade	Satisfeito (infraestrutura)	Suportado via Docker/Kubernetes com possibilidade de configuração de alta disponibilidade. Depende da infraestrutura da UA.
RNF-I01	Sistemas Heterogéneos	Satisfeito	Conexão configurada ao PostgreSQL como substituto dos sistemas da UA. A integração real depende da exposição de uma base de dados intermediária (Data Warehouse).
RNF-I02	Formatos	Satisfeito	Suporte a SQL, CSV, Excel e Parquet validado.
RNF-I03	ETL	Neutro	O Superset não inclui ETL nativo. Esta responsabilidade recai sobre o processo desenvolvido. O Superset consome o resultado do mesmo.
RNF-S01	Autenticação	Parcialmente Satisfeito	Autenticação OAuth2/OIDC com Keycloak implementada e validada no protótipo. KeycloakSecurityManager personalizado com logout federado via id_token_hint. Integração LDAP e SAML suportadas pela plataforma para produção.
RNF-S02	Autorização (RBAC)	Parcialmente Satisfeito	O Superset suporta RBAC e RLS, mas no protótipo não foram configurados roles institucionais nem row-level security.
RNF-S03	Proteção de Dados	Satisfeito	Dados de demonstração anonimizados. Superset suporta HTTPS e permissões por dataset.
RNF-S04	Audit Log	Parcialmente Satisfeito	Log de acessos disponíveis via interface de administração. Log detalhado de operações requer integração com sistema de logging externo.
RNF-U01	Interface Intuitiva	Satisfeito	Interface web moderna e responsiva. Utilizadores não técnicos conseguiram criar dashboards básicos em sessão de demonstração.
RNF-U02	Aprendizagem	Satisfeito	A documentação oficial é extensa. A curva de aprendizagem para administradores é elevada.
RNF-U03	Imagem Corporativa	Satisfeito (v6.0+)	Sistema de temas baseado em tokens Ant Design v5 permite personalização completa de cores, logótipo e tipografia sem recompilação do frontend.

ID	Requisito	Estado	Observações
RNF-U04	Acessibilidade	Parcialmente Satisfeito	Conformidade WCAG 2.1 parcial. Alguns elementos de visualização não são totalmente acessíveis a leitores de ecrã.

8.1 Síntese da Conformidade

Da análise apresentada, destacam-se os seguintes resultados:

- Satisfeito: 15 de 23 requisitos avaliados (65%) são integralmente satisfeitos pelo Apache Superset, sem necessidade de desenvolvimento adicional.
- Parcialmente Satisfeito: 7 de 23 requisitos (30%) são parcialmente satisfeitos, sendo que a lacuna resulta essencialmente de configuração adicional necessária (alertas, SMTP, acessibilidade) e não de limitações estruturais da ferramenta.
- Neutro: 1 requisito (ETL nativo) é classificado como neutro, uma vez que o Superset não inclui capacidades ETL — esta é uma responsabilidade de uma camada separada da arquitetura.
- Não Satisfeito: 0 requisitos classificados como não satisfeitos.

Este resultado demonstra que o Apache Superset satisfaz plenamente ou parcialmente a totalidade dos requisitos definidos, sem que nenhum seja estruturalmente inviável.

9. Parecer de Aprovação da Ferramenta

9.1 Pontos Fortes Confirmados

A implementação do cenário de demonstração e a análise aprofundada do Apache Superset permitem confirmar os seguintes pontos fortes da ferramenta, relevantes para o contexto da UA:

- Conformidade com requisitos: como demonstrado na seção 8, o Superset satisfaz ou satisfaz parcialmente a totalidade dos requisitos definidos, sem rejeições estruturais.
- Integração com PostgreSQL: a conexão ao Data Warehouse PostgreSQL foi configurada e testada com sucesso, com excelente desempenho em queries complexas sobre os datasets de demonstração.
- Dashboards e KPIs: os dashboards de demonstração validam a capacidade da ferramenta para responder às necessidades de visualização e monitorização de KPIs da UA, incluindo cross-filtering, drill-down e filtros globais.
- SQL Lab: a funcionalidade de SQL Lab revelou-se particularmente valiosa para analistas de dados da UA, permitindo exploração ad-hoc sem limitações sobre o Data Warehouse.
- Autenticação institucional implementada: a integração OAuth2/OIDC com Keycloak foi completamente configurada e validada no protótipo, com KeycloakSecurityManager personalizado, logout federado com id_token_hint e sincronização de roles. A arquitetura é diretamente transponível para o IdP institucional da UA.
- Imagem corporativa: o sistema de temas da versão 6.0 permite uma personalização adequada da interface para alinhamento com a identidade visual institucional, sem necessidade de modificar o código-fonte.
- Custo zero: sendo completamente open source e gratuito, o Superset é ideal para o contexto de uma universidade pública com restrições orçamentais.
- Comunidade ativa: a existência de uma comunidade ativa (GitHub, Slack, eventos anuais) garante evolução contínua da ferramenta e disponibilidade de suporte comunitário.

9.2 Pontos de Atenção e Mitigações

A análise identificou também um conjunto de pontos de atenção que deverão ser considerados durante a implementação em produção:

- Complexidade de configuração: a instalação e configuração do Superset (Docker, Celery, Redis, LDAP) exigem competências técnicas avançadas. Mitigação: alocar recursos técnicos dos STIC da UA para a administração da plataforma e documentar detalhadamente os procedimentos de instalação e configuração.
- Alertas por email: a funcionalidade de alertas requer a configuração de Celery Beat e de um servidor SMTP institucional. Mitigação: incluir esta configuração no plano de implementação, utilizando o servidor de email da UA.
- Documentação apenas em inglês: a ausência de documentação oficial em português pode dificultar a adoção por utilizadores menos proficientes. Mitigação: elaborar guias de utilização em português para os perfis de utilizador da UA (Gestores, Analistas, Viewers).
- Acessibilidade parcial: a conformidade WCAG 2.1 é incompleta. Mitigação: esta é uma limitação conhecida da ferramenta, a ser endereçada com CSS personalizado para os elementos mais críticos e monitorização das melhorias introduzidas em versões futuras.
- Integração LDAP híbrida: se for necessário suportar contas locais em simultâneo com LDAP, é necessário desenvolver um CustomSecurityManager. Mitigação: avaliar se este cenário é necessário e, se sim, planear o desenvolvimento deste componente adicional com antecedência.

9.3 Parecer Final

Com base no protótipo desenvolvido e na análise realizada, recomenda-se o Apache Superset como plataforma adequada para um cenário de Business Intelligence institucional na Universidade de Aveiro.

O protótipo demonstrou, com sucesso, a ligação entre uma base PostgreSQL com dados sintéticos representativos e a camada de visualização do Apache Superset. Foram criados dashboards com KPIs académicos, financeiros e organizacionais, permitindo validar funcionalidades centrais como a criação de datasets, gráficos interativos, filtros globais e indicadores agregados.

No entanto, a demonstração realizada deve ser entendida como um protótipo local e não como uma instalação de produção. Algumas funcionalidades importantes para um ambiente institucional real, como row-level security, cache Redis, Celery, alertas por email, personalização completa da interface e modelo dimensional completo não foram implementadas, embora sejam suportadas ou tecnicamente viáveis. A autenticação OAuth2/OIDC com Keycloak foi implementada e validada com sucesso no protótipo.

Assim, o Apache Superset revela-se uma solução adequada para a UA, sobretudo pelo seu carácter open source, pela flexibilidade na criação de dashboards, pela integração com PostgreSQL e pela capacidade de evolução para arquiteturas mais robustas. O próximo passo recomendado seria a realização de um piloto controlado, com integração a um subconjunto real de dados institucionais, separação entre metadados e Data Warehouse, configuração de autenticação institucional e validação junto de utilizadores finais.